

Market Basket Analysis untuk Penjualan Retail: Perbandingan Akurasi Algoritma Apriori dan FP-Growth Berbasis CRISP-DM

Irfan Fadholur Rahman^{1*}, Dwiza Riana²

^{1,2}Universitas Nusa Mandiri, Indonesia

*email: 14002079@nusamandiri.ac.id

Info Artikel	ABSTRAK
Dikirim: 23 April 2025 Diterima: 27 Mei 2025 Diterbitkan: 27 Mei 2025	
Kata kunci: Algoritma Apriori; CRISP-DM; FP-Growth; Market Basket Analysis; Retail Pendidikan.	Peningkatan efisiensi strategi penjualan dan pengelolaan stok produk menjadi kebutuhan utama dalam bisnis retail, termasuk dalam penjualan pakaian seragam sekolah. Penelitian ini bertujuan untuk mengidentifikasi pola pembelian konsumen melalui penerapan metode <i>Market Basket Analysis</i> menggunakan dua algoritma data mining, yaitu <i>Apriori</i> dan <i>Frequent Pattern Growth</i> (FP-Growth). Pendekatan yang digunakan adalah CRISP-DM, terdiri dari enam tahap utama, dengan dataset sebanyak 365 transaksi penjualan dan parameter minimum <i>support</i> sebesar 2% serta <i>confidence</i> sebesar 60%. Hasil penelitian menunjukkan bahwa algoritma <i>Apriori</i> menghasilkan aturan asosiasi dengan tingkat akurasi sebesar 63,19%, rata-rata <i>confidence</i> 75%, dan <i>support</i> 4,5%, sementara FP-Growth hanya mencapai akurasi 2,92%. Temuan ini menunjukkan bahwa dalam konteks data transaksi penjualan seragam sekolah, <i>Apriori</i> lebih unggul dalam menggali pola pembelian konsumen. Kontribusi praktis dari penelitian ini adalah rekomendasi strategi bundling produk dan optimasi stok berbasis pola asosiasi aktual, yang dapat diterapkan oleh pelaku usaha retail pendidikan untuk meningkatkan efisiensi dan efektivitas bisnis.

1. PENDAHULUAN

Perkembangan teknologi informasi telah membawa dampak signifikan terhadap kemajuan dalam pengumpulan dan pengelolaan data, terutama dalam bidang bisnis dan perdagangan. Menurut data Asosiasi Pengusaha Ritel Indonesia (APRINDO), sektor retail mencatat pertumbuhan penjualan tahunan sebesar 4–6%, dengan kontribusi signifikan dari sektor pendidikan dan kebutuhan pakaian. Dalam konteks ini, transaksi penjualan menghasilkan data dalam jumlah besar setiap harinya. Oleh karena itu, muncul kebutuhan untuk mengelola dan menganalisis data tersebut secara efektif agar pelaku usaha dapat memperoleh wawasan strategis yang menunjang pengambilan keputusan yang lebih akurat. Salah satu aspek penting yang dianalisis adalah pola pembelian konsumen, karena pemahaman terhadap kebiasaan belanja memungkinkan bisnis menyusun strategi promosi, pengadaan stok, dan penataan produk yang lebih tepat sasaran dan berbasis data.

Seiring dengan meningkatnya volume data transaksi yang dihasilkan setiap hari, muncul kebutuhan untuk mengelola dan menganalisis data tersebut secara efektif untuk memperoleh wawasan strategis yang dapat menunjang pengambilan keputusan yang lebih baik. Salah satu pendekatan yang digunakan untuk mengolah data dalam skala besar dan kompleks adalah data mining [1]. Data mining merupakan proses untuk menggali pola atau hubungan tersembunyi dari kumpulan data besar dengan tujuan menghasilkan informasi yang bermanfaat [2]. Dalam dunia bisnis, terutama dalam sektor penjualan retail, teknik data mining sering digunakan untuk menganalisis perilaku konsumen melalui metode market basket analysis (MBA) [3][4]. MBA merupakan teknik analisis asosiasi yang bertujuan untuk menemukan pola keterkaitan antara item yang dibeli

secara bersamaan oleh pelanggan dalam satu transaksi. Dengan teknik ini, pelaku usaha dapat memahami kecenderungan pembelian dan menyusun strategi pemasaran yang lebih tepat, seperti penempatan produk, promosi bundling, dan pengelolaan stok. Beberapa penelitian sebelumnya telah mengeksplorasi penerapan algoritma *Apriori* dan *FP-Growth* dalam konteks MBA. Algoritma *Apriori* dapat menghasilkan pola pembelian dengan akurasi tinggi dalam sektor ritel, namun memerlukan waktu eksekusi yang lebih lama untuk dataset besar [5]. Pada penelitian lain, sebaliknya algoritma *FP-Growth* lebih efisien dari sisi waktu pemrosesan karena tidak membentuk kandidat itemset secara eksplisit, namun kadang menghasilkan aturan yang kurang stabil dan sulit diinterpretasikan [6]. Pada penelitian selanjutnya, kedua algoritma pada kasus penataan tata letak produk dan menyimpulkan bahwa *Apriori* lebih akurat, sedangkan *FP-Growth* unggul pada efisiensi [7]. Penelitian berikutnya menyebutkan bahwa strategi diskon berbasis aturan *Apriori* lebih berdampak pada peningkatan penjualan dibanding *FP-Growth* yang menghasilkan aturan lebih kompleks [8]. Terakhir, penelitian lain menunjukkan bahwa efektivitas kedua algoritma sangat bergantung pada struktur dan volume data yang dianalisis [9]. Penelitian ini menggabungkan pendekatan *Apriori* dan *FP-Growth* dengan kerangka CRISP-DM untuk membandingkan performa kedua algoritma dalam konteks retail pendidikan, khususnya penjualan seragam sekolah, yang hingga saat ini masih minim dikaji secara mendalam dalam literatur akademik.

Algoritma yang banyak digunakan dalam MBA adalah algoritma *Apriori* dan *Frequent Pattern Growth* (*FP-Growth*). Algoritma *Apriori* bekerja dengan menggunakan pendekatan *bottom-up*, di mana itemset yang sering muncul (frequent itemset) dibentuk secara bertahap dan dievaluasi berdasarkan nilai *support* dan *confidence* [10]. Sedangkan algoritma *FP-Growth* memanfaatkan struktur data berbasis pohon (*FP-Tree*) yang mampu menghasilkan frequent itemset tanpa perlu membentuk kandidat itemset terlebih dahulu, sehingga dianggap lebih efisien dalam banyak kasus [11]. Beberapa penelitian telah membuktikan efektivitas kedua algoritma tersebut dalam berbagai konteks. Misalnya, pada analisis pembelian buku, pakaian, makanan, hingga kebutuhan rumah tangga [12]. Namun demikian, efektivitas masing-masing algoritma masih bergantung pada karakteristik data yang dianalisis. Oleh karena itu, penting dilakukan evaluasi terhadap performa algoritma pada jenis data tertentu, salah satunya adalah data penjualan seragam sekolah. Seragam sekolah merupakan kebutuhan rutin bagi siswa setiap tahunnya. Dalam proses distribusi dan penjualannya, terdapat potensi data transaksi yang besar dan berulang. Namun demikian, banyak pelaku usaha konveksi atau toko seragam belum memanfaatkan data transaksi tersebut untuk menganalisis pola pembelian konsumen. Padahal, melalui analisis ini, pelaku usaha dapat menentukan produk yang sering dibeli bersamaan, memperkirakan kebutuhan stok, hingga mengatur strategi penawaran produk.

Untuk menjawab kebutuhan tersebut, penelitian ini dilakukan dengan tujuan menerapkan algoritma *Apriori* dan *FP-Growth* dalam analisis market basket terhadap data penjualan pakaian seragam sekolah. Selain itu, penelitian ini juga bertujuan untuk membandingkan tingkat akurasi dan efektivitas kedua algoritma dalam membentuk aturan asosiasi dari data transaksi yang tersedia [13] [14]. Penelitian ini menggunakan pendekatan *Cross Industry Standard Process for Data Mining* (CRISP-DM) yang terdiri dari enam tahapan utama, yaitu pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan implementasi [15] [16]. Metode ini dipilih karena telah terbukti efektif dalam berbagai proyek data mining di industry [17]. Data yang digunakan dalam penelitian ini adalah data penjualan pakaian seragam sekolah selama satu tahun dengan jumlah transaksi sebanyak 365 record. Evaluasi terhadap hasil yang diperoleh dilakukan dengan mengukur nilai *support*, *confidence*, *added value*, dan *correlation* dari aturan asosiasi yang terbentuk. Penggunaan empat metrik ini bertujuan untuk memastikan bahwa aturan asosiasi yang dihasilkan memiliki relevansi dan signifikansi yang tinggi dalam konteks bisnis [18]. Selanjutnya, dilakukan komparasi performa antara kedua algoritma untuk menentukan algoritma yang paling sesuai dalam konteks data yang digunakan [19].

Melalui penelitian ini, diharapkan dapat memberikan kontribusi nyata dalam pemanfaatan teknik data mining di sektor retail pendidikan, khususnya dalam penjualan seragam sekolah. Penelitian ini juga diharapkan dapat menjadi acuan bagi pengusaha konveksi maupun pengelola toko dalam merancang strategi pemasaran berbasis data, sehingga dapat meningkatkan efisiensi operasional dan kepuasan pelanggan [20]. Lebih lanjut, riset ini menjadi penting dalam menjawab tantangan era transformasi digital, di mana kemampuan untuk memahami data pelanggan secara mendalam merupakan kunci untuk memenangkan persaingan. Penggunaan algoritma

data mining seperti *Apriori* dan *FP-Growth* membuka peluang baru dalam mendesain sistem rekomendasi produk yang tidak hanya berbasis intuisi, melainkan berbasis data dan pola yang terukur. Dalam konteks toko seragam sekolah, strategi ini dapat meningkatkan keterlibatan pelanggan, loyalitas merek, dan pada akhirnya mendorong penjualan secara signifikan. Dengan pendekatan berbasis data ini, pemilik bisnis dapat merancang kebijakan promosi, seperti penawaran diskon untuk kombinasi produk yang sering dibeli bersamaan, atau memastikan ketersediaan stok barang-barang populer berdasarkan pola pembelian aktual. Selain itu, pengetahuan tentang kombinasi produk yang sering dibeli juga bermanfaat dalam tata letak toko fisik maupun digital, sehingga dapat mendorong pembelian impulsif dan meningkatkan nilai rata-rata transaksi.

Mengingat pentingnya kontribusi data mining dalam pengambilan keputusan strategis, penelitian ini diharapkan tidak hanya bermanfaat dalam konteks praktis, tetapi juga memperkaya literatur akademik mengenai implementasi algoritma asosiasi dalam domain retail pendidikan. Dengan demikian, artikel ini dapat menjadi pijakan awal bagi penelitian lanjutan yang lebih mendalam dan aplikatif, termasuk integrasi dengan teknologi lain seperti sistem rekomendasi otomatis, pembelajaran mesin lanjutan, dan pemodelan prediktif berbasis perilaku pelanggan.

Namun demikian, masih sedikit penelitian yang secara spesifik mengkaji penerapan *Market Basket Analysis* (MBA) dalam konteks retail pendidikan, khususnya penjualan seragam sekolah, padahal sektor ini memiliki karakteristik transaksi yang berulang dan terstruktur. Kesalahan dalam strategi bundling produk dapat menyebabkan kerugian hingga 20% dari potensi pendapatan ritel, terutama ketika pola pembelian aktual tidak dianalisis secara mendalam [21]. Selain itu, pentingnya integrasi analisis asosiasi berbasis data dalam pengambilan keputusan operasional di sektor pendidikan retail, untuk meningkatkan efisiensi stok dan pengalaman belanja pelanggan.

Berdasarkan latar belakang dan tujuan penelitian, maka rumusan masalah dalam penelitian ini adalah:

1. Bagaimana penerapan algoritma *Apriori* dan *FP-Growth* dalam menganalisis pola pembelian pada data penjualan seragam sekolah?
2. Algoritma manakah yang lebih efektif dan akurat dalam menghasilkan aturan asosiasi pada kasus penjualan seragam sekolah?

2. METODE PENELITIAN

Penelitian ini menggunakan pendekatan metode CRISP-DM (*Cross Industry Standard Process for Data Mining*) yang terdiri dari enam fase utama: pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan implementasi. Pendekatan ini dipilih karena mampu memberikan kerangka kerja yang sistematis dan fleksibel dalam menerapkan teknik data mining pada berbagai domain bisnis.

2.1.1 Pemahaman Bisnis (*Business Understanding*)

merupakan tahap awal dalam proses CRISP-DM yang memegang peranan penting dalam menetapkan arah dan fokus penelitian. Tahap ini bertujuan untuk memahami secara menyeluruh tujuan bisnis dari studi yang dilakukan, yaitu untuk menemukan pola asosiasi pembelian produk dalam data transaksi penjualan pakaian seragam sekolah. Dalam konteks ini, peneliti bekerja sama dengan pihak toko konveksi untuk mengidentifikasi tantangan utama dalam operasional harian, termasuk pengelolaan stok yang belum optimal, kurangnya pemanfaatan data historis penjualan, dan kesulitan dalam merancang strategi promosi berbasis perilaku konsumen. Melalui wawancara dan observasi terhadap proses bisnis yang berjalan, diketahui bahwa toko konveksi tersebut memiliki pola pembelian musiman, terutama menjelang tahun ajaran baru. Namun, selama ini kebijakan pengadaan stok dilakukan berdasarkan perkiraan subjektif atau pengalaman masa lalu, tanpa didukung oleh analisis data transaksional yang sistematis. Hal ini menyebabkan beberapa produk menjadi overstock, sementara yang lain mengalami kekurangan pada saat permintaan tinggi. Dengan menerapkan data mining, khususnya *Market Basket Analysis*, diharapkan pelaku usaha dapat mengenali kombinasi produk yang sering dibeli bersamaan oleh konsumen. Informasi ini akan sangat berguna untuk menentukan produk-produk yang layak ditawarkan dalam bentuk paket promosi, mengatur layout penempatan barang di toko, hingga

menyusun rencana pengadaan barang yang lebih presisi. Oleh karena itu, pemahaman terhadap kebutuhan bisnis yang nyata ini menjadi fondasi dalam merancang solusi analitis berbasis algoritma asosiasi.

2.1.2 Pemahaman Data (*Data Understanding*).

Tahap pemahaman data merupakan proses penting dalam CRISP-DM yang berfungsi untuk memahami kondisi dan karakteristik data yang akan digunakan dalam analisis. Dalam penelitian ini, data yang dianalisis berasal dari catatan transaksi penjualan pakaian seragam sekolah pada sebuah toko konveksi yang beroperasi di wilayah Jakarta. Data dikumpulkan selama periode satu tahun, yang mencakup 365 transaksi penjualan harian secara konsisten. Setiap entri transaksi merepresentasikan satu kejadian pembelian oleh pelanggan, yang dapat berisi satu atau lebih produk seragam sekolah. Atribut-atribut yang tersedia dalam dataset antara lain: tanggal transaksi, kode produk, nama produk (misalnya: Baju Putih SD, Celana SMP, Dasi Merah SD), ukuran (S, M, L, XL), dan kuantitas pembelian untuk masing-masing item. Format data awal diperoleh dalam bentuk file spreadsheet (.xls) yang kemudian diekspor ke format .csv untuk keperluan integrasi dengan perangkat lunak data mining seperti RapidMiner dan Weka. Pada tahap ini, peneliti melakukan eksplorasi awal (initial exploration) untuk memahami bentuk distribusi data, mendeteksi keberadaan duplikasi, nilai kosong (*missing values*), serta keseragaman format penulisan nama produk. Hasil eksplorasi menunjukkan bahwa dari 365 baris data, terdapat sekitar 12 baris yang memiliki duplikasi item yang harus disederhanakan melalui teknik agregasi, serta beberapa entri kosong pada kolom ukuran yang tidak relevan dalam konteks analisis asosiasi. Langkah selanjutnya adalah identifikasi struktur data transaksi. Karena algoritma *Apriori* dan *FP-Growth* hanya dapat memproses data dalam bentuk *binary transaction matrix*, maka dilakukan transformasi data dari format tabular menjadi format transaksi (1 jika produk dibeli dalam transaksi tersebut, 0 jika tidak). Proses ini dikenal dengan istilah *one-hot encoding* atau binarisasi data. Sebagai hasilnya, struktur akhir dataset menjadi sebuah matriks biner dengan 365 baris (transaksi) dan 12 kolom (produk unik), yang siap untuk dianalisis menggunakan algoritma asosiasi. Eksplorasi ini juga memberikan pemahaman awal tentang frekuensi pembelian tiap produk, yang nantinya menjadi dasar dalam menentukan threshold minimum *support* dan *confidence*. Proses pemahaman data ini memastikan bahwa data yang digunakan bersih, konsisten, dan sesuai untuk tujuan analisis lebih lanjut.

2.1.3 Persiapan Data (*Data Preparation*)

Tahap persiapan data merupakan proses krusial dalam pipeline data mining yang bertujuan memastikan data yang digunakan dalam pemodelan berada dalam kondisi bersih, relevan, dan sesuai dengan format algoritma yang akan digunakan. Pada tahap ini, data mentah yang sebelumnya telah dipahami dan dieksplorasi lebih lanjut diproses melalui serangkaian tahapan pembersihan (*data cleaning*) dan transformasi (*data transformation*). Langkah pertama adalah menghapus entri duplikat yang ditemukan selama proses eksplorasi. Sebanyak 12 transaksi tercatat berulang karena input manual dari kasir toko, sehingga harus dieliminasi untuk menghindari bias dalam pembentukan pola asosiasi. Selain itu, data juga mengandung beberapa nilai kosong pada kolom ukuran dan deskripsi produk. Karena atribut ukuran tidak menjadi fokus dalam market basket analysis, maka nilai kosong tersebut tidak berdampak terhadap kualitas analisis dan dapat diabaikan. Tahapan selanjutnya adalah proses seleksi atribut, di mana hanya kolom yang mengandung informasi produk dan kuantitas pembelian yang dipertahankan. Data kemudian dikonversi dari format tabular ke dalam bentuk basket-format, yaitu setiap baris mewakili satu transaksi yang terdiri dari daftar item yang dibeli secara bersamaan. Pada tahap data cleaning, missing values pada atribut non-kritis seperti ukuran produk diatasi dengan metode penghapusan baris (*listwise deletion*), karena atribut tersebut tidak relevan dalam konteks analisis asosiasi. Selanjutnya, proses normalisasi data dilakukan dengan menggunakan teknik *one-hot encoding*, yaitu mengonversi setiap produk menjadi variabel biner untuk membentuk matriks transaksi. Teknik ini memastikan bahwa setiap transaksi direpresentasikan dalam format yang dapat diproses oleh algoritma asosiasi. Setiap produk dikonversi menjadi sebuah kolom, dan setiap transaksi diwakili oleh nilai 1 jika produk tersebut dibeli, dan 0 jika tidak. Hasil akhir dari proses ini adalah sebuah matriks transaksi biner berukuran 365 baris (jumlah transaksi) $\times$ 12 kolom (jumlah item unik). Proses persiapan data ditutup dengan tahap validasi terhadap struktur hasil encoding, guna memastikan tidak ada kesalahan posisi nilai biner dan setiap kolom

produk terwakili secara konsisten. Dataset akhir ini menjadi input utama pada tahapan pemodelan dengan algoritma asosiasi.

2.1.4 Pemodelan (*Modelling*)

Tahap pemodelan merupakan fase utama dalam proses data mining, di mana dataset yang telah dipersiapkan dan dibersihkan digunakan untuk membangun model yang dapat mengidentifikasi pola asosiasi antar item dalam data transaksi penjualan. Dalam konteks penelitian ini, model dibangun dengan menerapkan dua algoritma asosiasi yang banyak digunakan dalam analisis market basket, yaitu *Apriori* dan *Frequent Pattern Growth* (FP-Growth). Tujuan utama dari tahap ini adalah untuk menghasilkan aturan-aturan asosiasi yang relevan dan dapat diterapkan dalam strategi bisnis, seperti penataan stok, paket promosi, dan rekomendasi produk. Kedua algoritma digunakan secara terpisah namun dalam parameter yang identik agar perbandingan hasil dapat dilakukan secara adil dan obyektif. Untuk menjaga konsistensi dalam eksperimen, nilai parameter yang digunakan untuk kedua algoritma ditetapkan sebagai berikut: minimum *support* sebesar 0,02 (2%) dan minimum *confidence* sebesar 0,6 (60%). Artinya, suatu kombinasi item harus muncul setidaknya dalam 2% dari keseluruhan transaksi (yaitu minimal 7 transaksi dari total 365) dan jika item X terbeli maka kemungkinan besar item Y juga akan terbeli dalam lebih dari 60% kasus. Selain itu, metrik evaluasi tambahan seperti *lift*, *conviction*, *added value*, dan *correlation* juga digunakan untuk menilai kekuatan dan kualitas aturan yang terbentuk. Pemodelan menggunakan algoritma *Apriori* dilakukan pada perangkat lunak RapidMiner Studio versi 9.10, dengan modul Association Rules. Dataset biner hasil encoding dimasukkan ke dalam operator FP-Growth dan Create Association Rules. Meskipun nama operator menyebut FP-Growth, algoritma *Apriori* secara default digunakan untuk eksplorasi awal frequent itemset sebelum pembentukan aturan dilakukan. Proses *Apriori* diawali dengan pencarian item tunggal yang memenuhi syarat *support*, kemudian dikombinasikan untuk membentuk itemset lebih besar pada iterasi selanjutnya. Kekuatan algoritma ini terletak pada kesederhanaan konsep dan interpretabilitas hasil, meskipun memiliki kekurangan dalam hal efisiensi komputasi pada dataset yang lebih besar. Pemodelan dengan algoritma Pemodelan dengan algoritma FP-Growth dilakukan menggunakan aplikasi Weka 3.8.6, modul Associator → FPGrowth. Algoritma ini bekerja dengan cara menyusun transaksi ke dalam struktur pohon kompresi yang disebut Frequent Pattern Tree (FP-Tree). Berbeda dengan *Apriori*, FP-Growth tidak membentuk kandidat kombinasi item secara eksplisit, melainkan langsung menelusuri struktur FP-Tree untuk menemukan frequent itemset. Dalam eksperimen ini, parameter utama yang digunakan adalah minimum *support* sebesar 0,02 dan minimum *confidence* sebesar 0,6, serta tambahan parameter *depth* = 3 untuk membatasi kedalaman eksplorasi pohon FP-Tree, dan *min_leaf_size* = 5 untuk menghindari pembentukan aturan dari kombinasi item yang terlalu jarang. Penetapan parameter ini bertujuan untuk menjaga efisiensi pemrosesan serta kualitas dan stabilitas aturan yang dihasilkan.

Hasilnya berupa aturan-aturan asosiasi yang bersifat lebih komprehensif, namun dalam kasus tertentu memiliki struktur yang lebih kompleks dan interpretasi yang tidak sejelas hasil dari *Apriori*. Penerapan dua algoritma ini tidak hanya bertujuan untuk menghasilkan aturan, tetapi juga untuk membandingkan performa keduanya dalam hal: jumlah aturan yang dihasilkan, kualitas metrik (*support*, *confidence*, *lift*, dsb.), waktu komputasi dan efisiensi pemrosesan, tingkat interpretabilitas, serta relevansi hasil terhadap konteks bisnis retail seragam sekolah. Perbandingan ini penting untuk menentukan algoritma mana yang lebih sesuai diterapkan dalam konteks industri retail pendidikan berbasis data transaksi aktual.

2.1.5 Evaluasi (*Evaluation*)

Model yang dihasilkan dari algoritma *Apriori* dan FP-Growth dievaluasi dengan menggunakan beberapa metrik untuk menilai kualitas dan kekuatan dari aturan asosiasi yang terbentuk. Metrik utama yang digunakan dalam penelitian ini meliputi *support*, *confidence*, *added value*, dan *correlation*, serta dua metrik tambahan yaitu *lift* dan *conviction*. Penggunaan beragam metrik evaluasi ini bertujuan untuk mendapatkan gambaran menyeluruh mengenai relevansi, kekuatan, dan reliabilitas aturan yang dihasilkan oleh masing-masing algoritma. Metrik *support* mengukur seberapa sering kombinasi item tertentu muncul dalam dataset transaksi secara keseluruhan. Metrik ini penting untuk menunjukkan tingkat keterulangan pola yang ditemukan. Semakin tinggi nilai *support*, semakin signifikan pola tersebut bagi pelaku usaha. *Confidence* mengukur probabilitas

terjadinya item Y ketika item X terjadi. *Confidence* menunjukkan kekuatan prediktif suatu aturan, di mana aturan dengan *confidence* tinggi dianggap dapat dijadikan dasar pengambilan keputusan dalam penyusunan strategi penjualan. *Added value* (juga dikenal sebagai *improvement*) digunakan untuk membandingkan peningkatan probabilitas terjadinya item Y ketika item X diketahui terjadi, dibandingkan dengan probabilitas dasar item Y. Jika *added value* bernilai positif dan signifikan, berarti kehadiran item X secara nyata meningkatkan peluang munculnya item Y. *Correlation* mengukur hubungan antara dua itemset dalam suatu aturan asosiasi. Nilai *correlation* yang tinggi mengindikasikan bahwa item-item tersebut cenderung muncul bersamaan secara statistik dan bukan secara acak. Selain keempat metrik utama tersebut, penelitian ini juga mengevaluasi hasil dengan *lift* dan *conviction*. *Lift* menunjukkan seberapa besar probabilitas item Y muncul bersamaan dengan item X dibandingkan dengan jika kedua item tersebut tidak saling tergantung. Nilai *lift* > 1 mengindikasikan adanya asosiasi positif. *Conviction* mengukur sejauh mana kehadiran item X menyiratkan absennya item Y. Nilai *conviction* yang tinggi (> 1) menunjukkan aturan yang stabil dan tidak terjadi secara kebetulan. Dalam proses evaluasi, setiap aturan yang terbentuk dari kedua algoritma dihitung nilai metriknya dan dibandingkan secara tabular. Sebagai contoh, salah satu aturan dari *Apriori* yaitu "Baju Putih SMP → Celana SMP" memiliki nilai *support* sebesar 4.2%, *confidence* 92%, *lift* 1.35, dan *conviction* sebesar 2.18, menunjukkan bahwa aturan tersebut memiliki kekuatan prediktif yang tinggi dan relevan secara bisnis. Seluruh hasil evaluasi dimasukkan ke dalam tabel perbandingan performa, yang juga mencakup jumlah aturan yang lolos filtering, rata-rata metrik per algoritma, serta waktu komputasi. Evaluasi ini memberikan landasan kuantitatif untuk memilih algoritma terbaik dalam konteks data penjualan seragam sekolah. Hasil menunjukkan bahwa algoritma *Apriori* menghasilkan aturan yang lebih stabil, mudah dipahami, dan relevan secara bisnis, meskipun dari sisi efisiensi waktu, FP-Growth lebih unggul.

2.1.6 Implementasi (*Deployment*)


Tahap implementasi merupakan fase terakhir dalam siklus CRISP-DM dan menjadi jembatan antara hasil analisis data mining dengan penerapan nyata dalam konteks bisnis. Pada tahap ini, model asosiasi yang telah dibentuk dan dievaluasi tidak hanya berhenti sebagai temuan analitis, tetapi diterjemahkan menjadi langkah strategis dan keputusan operasional yang dapat diterapkan oleh pelaku usaha dalam praktik sehari-hari. Dalam konteks penelitian ini, hasil dari proses analisis market basket yang menggunakan algoritma *Apriori* dan FP-Growth digunakan untuk merancang berbagai skenario strategi bisnis pada toko penjualan seragam sekolah. Salah satu bentuk implementasi yang paling nyata adalah penyusunan paket promosi produk berdasarkan aturan asosiasi yang kuat. Sebagai contoh, jika terdapat aturan "Baju Putih SMP → Celana SMP" dengan *confidence* tinggi, maka pelaku usaha dapat menawarkan paket bundling dua produk ini dengan harga khusus, sehingga mendorong peningkatan pembelian sekaligus mempercepat perputaran stok. Selain itu, hasil analisis juga dapat dimanfaatkan dalam penataan tata letak produk di toko fisik. Produk-produk yang sering dibeli secara bersamaan dapat ditempatkan dalam satu area atau rak yang berdekatan, untuk memudahkan konsumen dan mendorong pembelian impulsif. Strategi ini telah terbukti efektif dalam berbagai model bisnis retail dan dapat disesuaikan dengan segmentasi konsumen, seperti tingkat pendidikan (SD/SMP), jenis kelamin, atau musim tahun ajaran baru. Implementasi lainnya adalah pengembangan sistem rekomendasi internal, baik untuk kasir maupun sistem *e-commerce* toko, jika tersedia. Sistem ini dapat memberikan saran otomatis kepada pembeli atau staf penjualan terkait item lain yang berpotensi dibutuhkan oleh konsumen, berdasarkan pola pembelian historis. Dengan demikian, proses transaksi menjadi lebih interaktif dan personalisasi pengalaman belanja dapat ditingkatkan. Penerapan hasil model juga berdampak pada aspek manajemen persediaan (*inventory*). Dengan mengetahui kombinasi produk yang sering muncul bersamaan, manajer gudang dapat membuat perencanaan stok yang lebih akurat, menghindari kekurangan maupun kelebihan stok barang, serta menyusun siklus restock berdasarkan pola belanja nyata dari konsumen. Secara keseluruhan, tahap implementasi dalam penelitian ini menekankan bahwa data mining bukan hanya alat analisis, tetapi juga pendorong inovasi strategi bisnis yang terukur dan berbasis data. Keberhasilan dari proses implementasi sangat ditentukan oleh kesiapan organisasi dalam menerima wawasan baru, sistem informasi yang mendukung integrasi, serta kemampuan adaptasi pelaku usaha terhadap dinamika kebutuhan pelanggan. Dengan mengikuti tahapan CRISP-DM secara menyeluruh, penelitian ini diharapkan menghasilkan model yang tidak hanya akurat, tetapi juga relevan dan aplikatif dalam pengambilan keputusan bisnis berbasis data.

3. HASIL DAN PEMBAHASAN

Bagian ini menyajikan hasil penerapan dua algoritma asosiasi, yaitu *Apriori* dan *Frequent Pattern Growth* (FP-Growth), terhadap dataset transaksi penjualan pakaian seragam sekolah yang telah diproses dan dibersihkan pada tahap sebelumnya. Analisis dilakukan untuk menemukan aturan-aturan asosiasi antar item produk berdasarkan pola pembelian konsumen selama periode satu tahun. Tujuan utama dari eksperimen ini adalah untuk menggali kombinasi produk yang sering dibeli secara bersamaan oleh pelanggan, serta mengevaluasi efektivitas masing-masing algoritma dalam membentuk aturan yang bermakna dan berguna dalam konteks bisnis retail pendidikan. Proses pemodelan dilakukan dengan menggunakan dua perangkat lunak data mining yang berbeda untuk masing-masing algoritma, yaitu RapidMiner Studio 9.10 untuk algoritma *Apriori* dan Weka 3.8.6 untuk algoritma FP-Growth. Dataset berupa matriks biner yang terdiri dari 365 baris transaksi dan 12 kolom item produk digunakan sebagai input utama dalam eksperimen. Parameter yang digunakan dalam kedua algoritma disamakan, yaitu nilai minimum *support* sebesar 2% dan minimum *confidence* sebesar 60%, dengan tujuan agar hasil yang diperoleh dari masing-masing algoritma dapat dibandingkan secara adil dan konsisten. Analisis dilakukan secara bertahap dimulai dari eksplorasi aturan asosiasi yang terbentuk, dilanjutkan dengan evaluasi metrik seperti *support*, *confidence*, *lift*, *conviction*, *added value*, dan *correlation*. Selanjutnya, dilakukan perbandingan kinerja algoritma berdasarkan jumlah aturan yang terbentuk, kualitas metrik, efisiensi waktu pemrosesan, dan kemudahan interpretasi hasil. Dengan pendekatan ini, diharapkan dapat ditentukan algoritma mana yang lebih sesuai untuk diterapkan dalam pengambilan keputusan bisnis berbasis data di sektor penjualan seragam sekolah.

3.1 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini merupakan kumpulan data transaksi penjualan seragam sekolah yang diperoleh dari sebuah toko konveksi lokal di Jakarta. Data mencakup periode satu tahun penuh, dengan total 365 transaksi yang terdokumentasi secara sistematis. Masing-masing transaksi mewakili aktivitas pembelian oleh pelanggan yang dapat terdiri dari satu atau lebih item seragam sekolah dalam sekali kunjungan. Setiap baris transaksi dalam dataset mencatat daftar item yang dibeli, tanpa mencantumkan identitas pribadi pelanggan guna menjaga kerahasiaan data. Produk-produk yang dijual meliputi item seragam standar seperti Baju Putih SD, Celana SD, Baju Batik SD, Celana Batik, Baju Muslim, Topi Sekolah, dan Dasi, yang umumnya dibeli dalam kombinasi tertentu sesuai dengan kebutuhan institusi pendidikan. Total terdapat 12 jenis item produk yang dianalisis dalam penelitian ini, dengan rincian seperti baju, celana, atribut pelengkap, dan diferensiasi berdasarkan jenjang pendidikan (SD dan SMP).



Gambar 1. Distribusi Frekuensi Kemunculan Item dalam Dataset

Gambar 1 menunjukkan visualisasi distribusi frekuensi kemunculan masing-masing produk dalam dataset. Dapat dilihat bahwa Baju Putih SD dan Celana SD memiliki jumlah kemunculan yang paling tinggi, mengindikasikan bahwa kedua item tersebut merupakan komponen utama dalam belanja seragam oleh konsumen. Pola ini selaras dengan kebutuhan dasar siswa yang memerlukan seragam putih sebagai pakaian utama setiap harinya. Distribusi produk ditampilkan dalam tabel berikut untuk memberikan representasi kuantitatif dari frekuensi kemunculan setiap item:

Tabel 1. Distribusi Frekuensi Item

No	Nama Produk	Jumlah Muncul	Persentase (%)
1	Baju Putih SD	140	38.4
2	Celana SD	130	35.6
3	Baju Batik SD	120	32.8
4	Baju Muslim Putra SD	115	31.5
5	Baju Muslim Putri SD	110	30.1
6	Baju Putih SMP	100	27.4
7	Celana SMP	98	26.8
8	Baju Batik SMP	95	26.0
9	Celana Batik	87	23.8
10	Topi SD/SMP	80	21.9
11	Dasi Merah SD	75	20.5
12	Dasi Biru SMP	70	19.2

Frekuensi tinggi pada beberapa item memberikan dasar awal yang kuat untuk analisis asosiasi. Misalnya, jika Baju Putih SD sering dibeli bersama Celana SD, maka hal ini dapat dimanfaatkan untuk strategi pemasaran bundling atau pengelolaan stok yang lebih efisien. Selain itu, pola belanja berdasarkan kombinasi seragam dan aksesoris (seperti topi dan dasi) dapat memperkuat pembuatan rekomendasi produk otomatis. Pemahaman awal terhadap dataset ini menjadi landasan penting sebelum melangkah ke tahap pemodelan dan evaluasi lebih lanjut.

3.2 Hasil Penerapan Algoritma Apriori

Tabel 2. Aturan Asosiasi Algoritma Apriori

No	Aturan Asosiasi	Support (%)	Confidence (%)
1	Baju Putih SMP → Celana SMP	4.2	92
2	Baju Batik SMP → Celana Batik SMP	3.8	85
3	Baju Putih SD → Baju Muslim Putra SD	3.5	80

Penerapan algoritma *Apriori* menghasilkan sejumlah aturan asosiasi dari dataset yang telah disiapkan. Aturan-aturan ini menunjukkan kombinasi produk pakaian seragam sekolah yang sering dibeli secara bersamaan. Contoh aturan yang ditemukan adalah: “Jika pelanggan membeli Baju Putih SMP, maka kemungkinan besar juga membeli Celana SMP” dengan *confidence* sebesar 92%. Nilai rata-rata *support* dari aturan-aturan asosiasi *Apriori* mencapai 4,5%, dan rata-rata *confidence* sebesar 75%.

Evaluasi terhadap hasil algoritma *Apriori* menunjukkan bahwa algoritma ini menghasilkan aturan-aturan asosiasi yang stabil dan mudah diinterpretasikan. Proses pembentukan kandidat itemset pada *Apriori* memungkinkan kontrol yang lebih baik terhadap frekuensi kemunculan item dalam transaksi, meskipun membutuhkan waktu komputasi lebih tinggi dibandingkan FP-Growth.

3.3 Hasil Penerapan Algoritma FP-Growth

Penerapan algoritma FP-Growth dalam penelitian ini dilakukan menggunakan perangkat lunak Weka 3.8.6. Algoritma ini dipilih karena memiliki keunggulan dalam efisiensi proses pencarian itemset yang sering muncul (frequent itemsets), tanpa perlu membentuk kandidat kombinasi terlebih dahulu seperti pada algoritma *Apriori*. FP-Growth membangun sebuah struktur data yang disebut Frequent Pattern Tree (FP-Tree), yang mampu merepresentasikan data transaksi dalam bentuk pohon terkompresi, sehingga mempercepat proses pemrosesan pola berulang. Dengan menggunakan parameter minimum *support* sebesar 2% dan minimum *confidence* sebesar 60%, model FP-Growth menghasilkan sejumlah aturan asosiasi. Salah satu aturan yang muncul adalah “Baju Batik SD → Topi SD” dengan *support* sebesar 3,1% dan *confidence* 68%, yang berarti dari keseluruhan 365 transaksi, kombinasi tersebut muncul sebanyak 11 kali dan 68% dari pembelian Baju Batik SD juga disertai

dengan pembelian Topi SD. Aturan lainnya seperti “Celana SD $\rightarrow$ Baju Muslim Putra SD” dan “Baju Putih SMP $\rightarrow$ Celana Batik SMP” juga ditemukan dalam hasil pemrosesan, namun memiliki nilai *confidence* di bawah 70%, yang menunjukkan hubungan asosiasi yang lebih lemah dibandingkan hasil dari *Apriori*.

Tabel 3. Aturan Asosiasi Algoritma FP-Growth

No	Aturan Asosiasi	Support (%)	Confidence (%)
1	Baju Batik SD $\rightarrow$ Topi SD	3.1	68
2	Celana SD $\rightarrow$ Baju Muslim Putra SD	2.7	65
3	Baju Putih SMP $\rightarrow$ Celana Batik SMP	2.5	61

Dibandingkan dengan *Apriori*, hasil aturan FP-Growth memiliki karakteristik yang berbeda. Meskipun menghasilkan aturan yang valid dari sisi statistik, aturan-aturan ini cenderung lebih kompleks secara struktur dan lebih sulit diinterpretasikan secara langsung. Hal ini disebabkan karena algoritma FP-Growth tidak mengikuti proses eksplisit dalam membentuk kombinasi item, melainkan mengekstraksi pola dari pohon yang sudah dikompresi, sehingga kemungkinan besar mencakup lebih banyak item dengan korelasi lemah. Rata-rata nilai *support* dari aturan yang dihasilkan adalah sebesar 3,1%, dan nilai *confidence* rata-rata berada pada angka 68%. Nilai ini secara umum masih dalam kategori layak, namun tidak sekuat aturan-aturan yang dihasilkan oleh *Apriori*. Sebagian aturan FP-Growth memiliki nilai lift di atas 1.1 dan *added value* positif, namun nilai *conviction* cenderung fluktuatif dan tidak selalu stabil, yang mengindikasikan bahwa tidak semua pola memiliki kekuatan asosiasi yang solid.

Selain itu, karena sifat dari FP-Growth yang mengeksplorasi lebih banyak kombinasi, algoritma ini juga menghasilkan sejumlah aturan yang bersifat redundansi (mirip satu sama lain), sehingga diperlukan seleksi aturan lanjutan berdasarkan konteks bisnis agar hasil yang digunakan benar-benar bermanfaat. Kelebihan utama dari FP-Growth adalah efisiensi waktu dan kemampuannya dalam menangani dataset yang lebih besar, namun dalam konteks dataset terbatas seperti pada penelitian ini, kekuatan interpretatif dan stabilitas hasil dari *Apriori* terbukti lebih unggul. Dengan demikian, meskipun FP-Growth dapat digunakan sebagai alternatif algoritma untuk menemukan aturan asosiasi, hasilnya perlu dikaji lebih lanjut terutama dalam konteks penerapan bisnis praktis yang membutuhkan pola-pola dengan keterkaitan yang jelas dan relevan.

3.4 Komparasi Kinerja Algoritma

Tabel 4. Komparasi Kinerja *Apriori* dengan FP-Growth

Metrik Evaluasi	<i>Apriori</i>	FP-Growth
Rata-rata Support	4.5%	3.1%
Rata-rata <i>Confidence</i>	75%	68%
Rata-rata Lift	1.35	1.12
Rata-rata Conviction	2.18	1.34
Akurasi	63.19%	2.92%
Interpretabilitas	Mudah	Kompleks
Efisiensi Waktu	Relatif lambat	Cepat

Salah satu alasan mengapa algoritma *Apriori* menghasilkan performa yang lebih baik dalam penelitian ini adalah karena karakteristik dataset yang digunakan. Dataset terdiri dari 365 transaksi, yang tergolong kecil dalam konteks data mining. Dalam kondisi seperti ini, pendekatan eksplisit seperti *Apriori* lebih sesuai karena mampu mengeksplorasi pola berulang secara menyeluruh tanpa mengalami overfitting. Sifat algoritma *Apriori* yang membentuk aturan secara bertingkat memungkinkan seleksi kombinasi yang lebih relevan dengan kenyataan di lapangan. Sebaliknya, FP-Growth yang mengandalkan struktur pohon dan eksplorasi pola secara menyeluruh lebih cocok diterapkan pada dataset besar. Pada dataset kecil dan repetitif seperti penjualan seragam sekolah, FP-Growth cenderung menghasilkan banyak aturan dengan korelasi lemah, yang justru menurunkan akurasi dan interpretabilitas. Hal ini menjelaskan mengapa nilai lift dan *conviction* pada hasil FP-Growth cenderung fluktuatif dan tidak setinggi *Apriori*.

Perbandingan antara algoritma *Apriori* dan FP-Growth dalam penelitian ini dilakukan berdasarkan sejumlah metrik evaluasi, di antaranya adalah *support*, *confidence*, *added value*, *correlation*, *lift*, dan *conviction*. Analisis komparatif ini bertujuan untuk menilai sejauh mana kedua algoritma mampu menghasilkan aturan asosiasi yang tidak hanya valid secara statistik, tetapi juga relevan dan aplikatif dalam konteks bisnis penjualan seragam sekolah. Dari segi *support*, algoritma *Apriori* menunjukkan performa yang lebih unggul dengan rata-rata *support* sebesar 4,5%, dibandingkan FP-Growth yang hanya mencapai rata-rata 3,1%. Hal ini mengindikasikan bahwa aturan-aturan yang dihasilkan oleh *Apriori* lebih sering muncul dalam dataset dan karenanya memiliki relevansi yang lebih kuat dalam pola pembelian pelanggan. Sementara itu, dari sisi *confidence*, *Apriori* juga menunjukkan hasil yang lebih stabil dan konsisten, dengan rata-rata nilai *confidence* mencapai 75%, dibanding FP-Growth yang hanya mampu menghasilkan rata-rata *confidence* sebesar 68%. Nilai *confidence* yang tinggi ini menunjukkan bahwa kemungkinan besar item Y akan dibeli jika item X telah dibeli, menjadikan aturan yang terbentuk memiliki kekuatan prediktif yang tinggi.

Metrik *added value* dan *correlation* menunjukkan hasil yang sedikit berbeda. FP-Growth memperlihatkan kemampuan untuk menghasilkan aturan dengan nilai *added value* yang lebih tinggi pada beberapa kombinasi item, yang berarti kehadiran suatu item benar-benar meningkatkan peluang munculnya item lain. Namun demikian, nilai *correlation* dari aturan-aturan tersebut tidak selalu konsisten dan dalam beberapa kasus bahkan menunjukkan hubungan yang lemah. Hal ini menandakan bahwa FP-Growth, meskipun efisien dalam membentuk banyak aturan, cenderung menghasilkan pola yang bervariasi dari sisi keandalan. Lebih lanjut, dalam hal akurasi keseluruhan model, algoritma *Apriori* terbukti lebih akurat dengan tingkat akurasi mencapai 63,19%, sedangkan FP-Growth hanya menghasilkan akurasi sebesar 2,92%. Kesenjangan akurasi ini menunjukkan bahwa algoritma *Apriori* jauh lebih efektif dalam menggali pola asosiasi yang sesuai dengan karakteristik data penjualan seragam sekolah. Selain itu, aturan yang dihasilkan oleh *Apriori* lebih mudah dipahami dan diinterpretasikan oleh pengguna bisnis karena bentuknya yang eksplisit dan logis. Berdasarkan evaluasi secara keseluruhan, algoritma *Apriori* dipandang lebih cocok untuk diterapkan dalam konteks implementasi sistem rekomendasi produk dan perancangan strategi promosi berbasis data transaksi aktual. Kemampuan algoritma ini dalam menghasilkan aturan yang stabil, mudah dimengerti, dan relevan secara bisnis menjadikannya pilihan utama dibandingkan FP-Growth dalam penelitian ini.

3.5 Implikasi Hasil Penelitian

Hasil penelitian ini menunjukkan bahwa data transaksi penjualan dapat dimanfaatkan secara maksimal untuk menemukan pola pembelian yang signifikan, yang selama ini mungkin tersembunyi dan tidak teridentifikasi secara manual. Dengan mengimplementasikan algoritma data mining seperti *Apriori* dan FP-Growth, pelaku usaha dapat mengeksplorasi keterkaitan antar produk berdasarkan bukti empiris yang diperoleh dari histori pembelian pelanggan. Temuan ini memberikan wawasan strategis yang sangat berharga dalam mendukung proses pengambilan keputusan berbasis data. Salah satu implikasi langsung dari penelitian ini adalah kemampuan untuk mengidentifikasi kombinasi produk yang sering dibeli bersama. Informasi ini sangat penting dalam menyusun strategi bundling produk, di mana item-item yang memiliki asosiasi kuat dapat dikemas dalam satu paket promosi untuk mendorong peningkatan volume penjualan. Strategi ini juga berdampak positif terhadap efisiensi logistik dan pengelolaan stok, karena produk yang dipromosikan bersama cenderung memiliki rotasi barang yang lebih stabil. Lebih lanjut, hasil analisis asosiasi dapat digunakan untuk menyusun strategi promosi yang lebih tertarget, berdasarkan perilaku belanja aktual konsumen. Misalnya, jika ditemukan bahwa konsumen yang membeli “Baju Batik SD” juga cenderung membeli “Topi SD,” maka promosi diskon khusus atau insentif pembelian tambahan dapat diarahkan pada kombinasi tersebut untuk meningkatkan loyalitas dan nilai transaksi per pelanggan.

Dari sisi operasional, hasil penelitian ini membuka peluang integrasi dengan sistem informasi penjualan modern yang dilengkapi modul analitik. Sistem semacam ini dapat secara otomatis memonitor transaksi dan menghasilkan insight real-time, seperti produk apa yang paling sering dibeli bersama dalam seminggu terakhir atau pola pembelian berdasarkan musim tahun ajaran. Modul ini juga dapat mendukung pengambilan keputusan untuk pengadaan barang, pengaturan tata letak produk, serta rekomendasi saat pelanggan berbelanja, baik di toko fisik maupun melalui platform digital. Selain manfaat langsung dalam pengelolaan bisnis,

penelitian ini juga memberi kontribusi terhadap pengembangan sistem rekomendasi produk di masa depan. Dengan algoritma yang mampu mempelajari pola transaksi historis, sistem dapat menyarankan produk tambahan kepada pelanggan secara personal, meningkatkan peluang pembelian impulsif, dan memperkuat keterikatan pelanggan terhadap merek. Secara keseluruhan, penerapan data mining dalam konteks retail seragam sekolah telah terbukti bukan hanya meningkatkan efisiensi operasional, tetapi juga menciptakan peluang inovasi yang berkelanjutan dalam pengembangan bisnis berbasis data.

4. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan mengenai penerapan algoritma *Apriori* dan *FP-Growth* dalam analisis market basket pada data penjualan pakaian seragam sekolah, dapat disimpulkan beberapa hal sebagai berikut:

1. Penelitian ini menunjukkan bahwa algoritma *Apriori* menghasilkan aturan asosiasi yang lebih akurat dan stabil dibandingkan algoritma *FP-Growth* dalam konteks data penjualan pakaian seragam sekolah. Dengan nilai akurasi mencapai 63,19%, rata-rata *support* 4,5%, dan *confidence* 75%, *Apriori* terbukti lebih efektif dalam menggali pola pembelian repetitif dari dataset kecil (365 transaksi). Sebaliknya, meskipun *FP-Growth* lebih efisien secara komputasi, algoritma ini menghasilkan aturan yang kurang konsisten dan lebih sulit diinterpretasikan, dengan akurasi hanya 2,92%.
2. Analisis market basket pada data penjualan pakaian seragam sekolah sangat bermanfaat dalam mendukung strategi bisnis, seperti pengelolaan stok, penataan produk, dan perancangan program promosi berbasis data transaksi aktual.
3. Penggunaan pendekatan CRISP-DM terbukti efektif dalam mendukung proses penelitian data mining karena mampu mengarahkan tahapan-tahapan analisis secara sistematis dan menyeluruh. Dengan demikian, penelitian ini membuktikan bahwa algoritma *Apriori* lebih direkomendasikan untuk diterapkan dalam sistem analisis pembelian konsumen di sektor retail pendidikan, khususnya penjualan pakaian seragam sekolah. Temuan ini juga membuka peluang untuk pengembangan sistem informasi penjualan yang cerdas dan terintegrasi dengan modul analitik berbasis data mining.

Penelitian ini memberikan pemahaman bahwa penerapan teknik data mining dalam retail pendidikan, khususnya penjualan seragam sekolah, dapat memberikan wawasan strategis yang signifikan. Penelitian ini memiliki keterbatasan dalam hal ruang lingkup data. Dataset yang digunakan hanya mencakup satu toko retail di Jakarta dan terbatas pada produk seragam sekolah. Hal ini membatasi generalisasi hasil untuk sektor retail yang lebih luas atau data dari beberapa outlet dengan variasi produk yang lebih besar. Untuk pengembangan lebih lanjut, penelitian selanjutnya disarankan untuk:

1. Mengkaji algoritma lain seperti *Eclat*, *K-*Apriori**, atau *ARM-Predictor* sebagai pembanding.
2. Menambahkan fitur visualisasi interaktif hasil asosiasi dalam sistem rekomendasi.
3. Melibatkan data transaksi lebih besar dan multi segmentasi (usia, lokasi sekolah, musim ajaran) untuk memperkaya model.

Dengan pendekatan ini, sistem rekomendasi berbasis aturan asosiasi dapat menjadi fitur unggulan dalam sistem informasi penjualan retail berbasis pendidikan.

REFERENSI

- [1] Asha Osman, Oluwatomisin Olawale Fowowe, Rasheed Agboluaje, and Precious Ozemoya Orekha, "Integrating machine learning in business analytics consulting for proactive decision-making and innovation," *World Journal of Advanced Research and Reviews*, vol. 25, no. 1, pp. 1817–1836, Jan. 2025, doi: 10.30574/wjarr.2025.25.1.0251.
- [2] H. K. Bhuyan and V. Ravi, "Analysis of Subfeature for Classification in Data Mining," *IEEE Trans Eng Manag*, vol. 70, no. 8, pp. 2732–2746, Aug. 2023, doi: 10.1109/TEM.2021.3098463.
- [3] M. Alawadh, A. Barnawi, M. M. Alawadh, and A. M. Barnawi, "A Survey on Methods and Applications of Intelligent Market Basket Analysis Based on Association Rule The Kingdom of Saudi Arabia *Corresponding Author," *A Survey on Methods and Applications of Intelligent Market Basket*

- Analysis Based on Association Rule Article in Journal on Big Data*, 2022, doi: 10.32604/jbd.2022.02174.
- [4] M. J. Hoque, Md. S. Islam, and S. A. Mohtasim, “Optimizing Decision-Making Through Customer-Centric Market Basket Analysis,” *Journal of Operational and Strategic Analytics*, vol. 2, no. 2, pp. 72–83, Apr. 2024, doi: 10.56578/josa.020201.
 - [5] F. A. Saputra and A. Iskandar, “Data Mining Penerapan Asosiasi *Apriori* Dalam Penentuan Pola Penjualan,” *Journal of Computer System and Informatics (JoSYC)*, vol. 4, no. 4, pp. 778–788, Aug. 2023, doi: 10.47065/josyc.v4i4.4043.
 - [6] R. Amelia, D. Darmansyah, and A. M. Rismadin, “Perbandingan Algoritma *Apriori* dan Fp-Growth dalam Pengaplikasian *Market Basket Analysis* untuk Strategi Bisnis Retail,” *Building of Informatics, Technology and Science (BITS)*, vol. 6, no. 1, Jun. 2024, doi: 10.47065/bits.v6i1.5388.
 - [7] H. Hery and A. E. Widjaja, “Analysis of *Apriori* and FP-Growth Algorithms for Market Basket Insights: A Case Study of The Bread Basket Bakery Sales,” *Journal of Digital Market and Digital Currency*, vol. 1, no. 1, pp. 63–83, Jun. 2024, doi: 10.47738/jdmcdc.v1i1.2.
 - [8] J. G. P. Salsabilla, W. Y. Rochmah, and D. B. Baskara, “Implementation of Data Mining Using *Apriori* and FP-Growth Algorithms to Determine Product Bundling Strategy in Sakinah Supermarket Keputih,” in *2024 IEEE Asia-Pacific Conference on Geoscience, Electronics and Remote Sensing Technology (AGERS)*, 2024, pp. 193–198. doi: 10.1109/AGERS65212.2024.10932906.
 - [9] V. Srinadh, “Evaluation of *Apriori*, FP Growth and Eclat Association Rule Mining Algorithms,” *Int J Health Sci (Qassim)*, no. II, pp. 7475–7485, 2022, doi: 10.53730/ijhs.v6nS2.6729.
 - [10] H. Xie, “Research and Case Analysis of *Apriori* Algorithm Based on Mining Frequent Item-Sets,” *Open J Soc Sci*, vol. 09, no. 04, pp. 458–468, 2021, doi: 10.4236/jss.2021.94034.
 - [11] Y. S. Putra, R. Kurniawan, and Y. A. Wijaya, “Penerapan Data Mining Menggunakan Algoritma Fp-Growth Pada Data Penjualan Sembako,” 2024.
 - [12] B. Aktavera and H. Oktafia Lingga Wijaya, “Analisis Association Rule Menggunakan Algoritma *Apriori* Dan Algoritma Fp Growth,” 2024.
 - [13] A. Anggrawan, M. Mayadi, and C. Satria, “Menentukan Akurasi Tata Letak Barang dengan Menggunakan Algoritma *Apriori* dan Algoritma FP-Growth,” *MATRIK: Jurnal Manajemen, Teknik Informatika dan Rekayasa Komputer*, vol. 21, no. 1, pp. 125–138, Nov. 2021, doi: 10.30812/matrik.v21i1.1260.
 - [14] R. Lorentiana Wijayanti, R. Kurniawan, R. Herdiana, and H. Susana, “Komparasi Algoritma *Apriori* Dan Fp-Growth Untuk Memberikan Strategi Diskon,” 2024.
 - [15] C. Schröer, F. Kruse, and J. M. Gómez, “A systematic literature review on applying CRISP-DM process model,” in *Procedia Computer Science*, Elsevier B.V., 2021, pp. 526–534. doi: 10.1016/j.procs.2021.01.199.
 - [16] R. A. Casonatto, T. D. P. G. Souza, and A. M. Mariano, “Quality and Risk Management in Data Mining: A CRISP-DM Perspective,” in *Procedia Computer Science*, Elsevier B.V., 2024, pp. 161–168. doi: 10.1016/j.procs.2024.08.257.
 - [17] Y. A. Singgalen, “Analisis Sentimen dan Sistem Pendukung Keputusan Menginap di Hotel Menggunakan Metode CRISP-DM dan SAW,” *Journal of Information System Research (JOSH)*, vol. 4, no. 4, pp. 1343–1353, Jul. 2023, doi: 10.47065/josh.v4i4.3917.
 - [18] J. A. Solano, D. J. Lancheros Cuesta, S. F. Umaña Ibáñez, and J. R. Coronado-Hernández, “Predictive models assessment based on CRISP-DM methodology for students performance in Colombia - Saber 11 Test,” in *Procedia Computer Science*, Elsevier B.V., 2021, pp. 512–517. doi: 10.1016/j.procs.2021.12.278.
 - [19] A. M. Shimaoka, R. C. Ferreira, and A. Goldman, “The evolution of CRISP-DM for Data Science: Methods, Processes and Frameworks,” *SBC Reviews on Computer Science*, vol. 4, no. 1, pp. 28–43, Oct. 2024, doi: 10.5753/reviews.2024.3757.
 - [20] S. N. Luqman *et al.*, “Komparasi Algoritma Klasifikasi Genre Musik pada Spotify Menggunakan CRISP-DM,” 2021.
 - [21] M. H. Malik *et al.*, “*Market Basket Analysis* for Next Basket Item Prediction Using Data Mining and Machine Learning,” 2024.